



Eraraya Ricardo Muten (13316082)  
Program Studi Teknik Fisika  
Laboratorium Teknologi Kuantum, Institut Teknologi Bandung

# Desain Pengklasifikasi Citra Kuantum dengan Skema Data Re-uploading Quantum Convolution dan Data Re-uploading Classifier

Dosen Pembimbing:  
Ir. Nugraha, Ph.D. (196401151989021001)  
Prof. Andriyan Bayu Suksmono M.T., Ph.D. (196607051996031002)



Kode Sumber


## Latar Belakang

**Stagnasi Hukum Moore dan Komputasi Kuantum Era NISQ**  
Resiko stagnasi Hukum Moore dan kebutuhan kekuatan komputasi yang terus bertambah menyebabkan dimulainya eksplorasi komputasi kuantum sebagai alternatif teknologi komputasi yang berpotensi meningkatkan performa komputasi dalam berbagai bidang, termasuk pembelajaran mesin dan pengolahan data. Perkembangan komputasi kuantum sangat pesat dalam beberapa tahun terakhir ini, namun perangkat keras yang ada saat ini sangat terbatas, masih dalam kategori *Noisy Intermediate Scale Quantum* (NISQ).

**Strategi Era NISQ: Algoritma Kuantum Variasional**  
Batasan ini kemudian menjadi pendorong berkembangnya Algoritma Kuantum Variasional (AKV), algoritma kuantum yang memanfaatkan algoritma optimisasi klasik untuk mengoptimisasi parameter pada sirkuit kuantum variasional (SKV) agar dapat menghasilkan keadaan kuantum tertentu, sebagai strategi andalan pada komputasi kuantum dalam era NISQ.

## Tujuan dan Kebaruan Penelitian

AKV telah dimanfaatkan dalam beberapa penelitian sebelumnya untuk klasifikasi citra MNIST namun akurasi yang dihasilkan relatif masih rendah.



Sehingga tujuan penelitian ini adalah merancang pengklasifikasi citra kuantum untuk data "MNIST" berbasis metode AKV dengan target:

1. Akurasi klasifikasi biner yang lebih baik dari penelitian terkait sebelumnya.
2. Algoritma diekspansi ke klasifikasi banyak kelas.

Adapun kebaruan yang ditawarkan penelitian ini sebagai berikut:

1. Modifikasi skema pengklasifikasi kuantum *Data Re-uploading Classifier* (DRC)[1] menjadi DRC dengan Representasi Biner (DRC-RB) yang meningkatkan akurasi klasifikasi banyak kelas.
2. Mengajukan skema *Data Re-uploading Quantum Convolution* (DRQConv), yaitu skema konvolusi citra dengan sirkuit kuantum yang terinspirasi dari lapisan konvolusi pada Jaringan Saraf Tiruan Konvolusi (JSTK).

## Penelitian Terkait

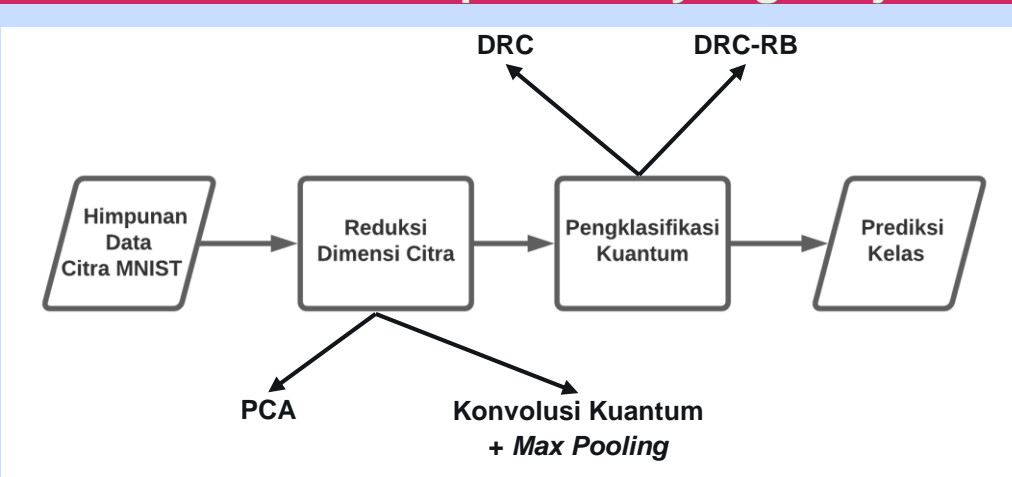
**E. Farhi dan H. Neven. Google AI Quantum. Agustus 2018.[2]**  
Membutuhkan 17 qubit, menghasilkan akurasi latihan dan uji 88% dan 90%.

**Skolik, et al. Volkswagen Data:Lab. Januari 2021.[3]**  
Dimensi citra direduksi dengan PCA. Akurasi uji 73% (10 qubit).

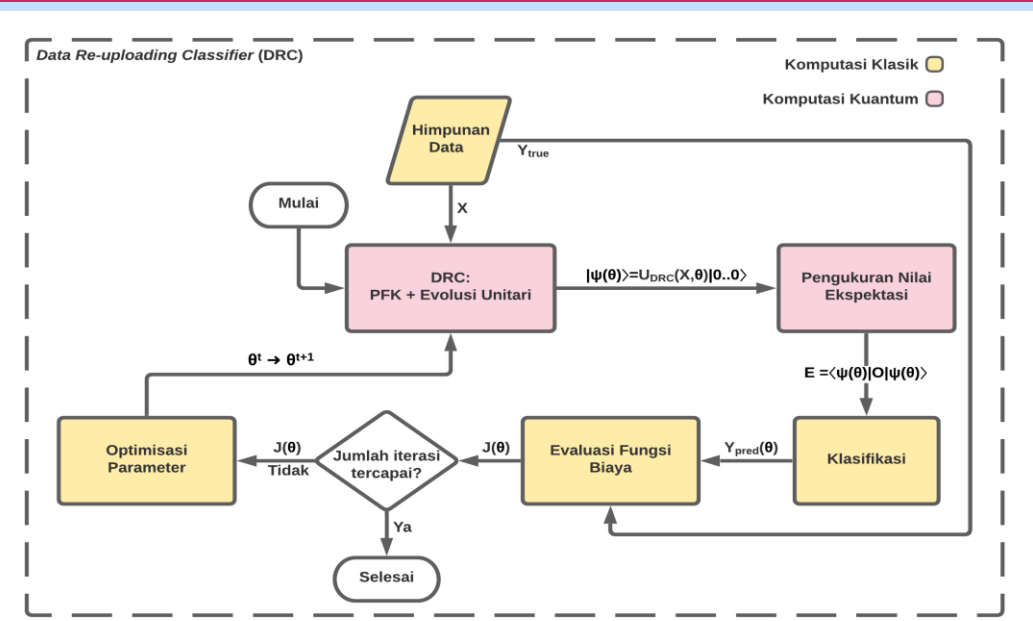
Ketiga penelitian ini tidak melakukan ekspansi ke klasifikasi banyak kelas.

**S. Mardirosian. Leiden University. Juli 2019.[4]**  
Dimensi citra direduksi dengan PCA. Akurasi latihan dan uji terbaik sebesar 97% dan 90% (3 qubit).

## Aliran Data Tiap Skema yang Diuji



## Pengklasifikasi Kuantum DRC dan DRC-RB



Pada skema DRC, penyematan fitur dan evolusi unitari digabung ke dalam satu sirkuit yang sama. Misalkan terdapat sampel data  $x$ , sampel tersebut dikalikan dengan suatu parameter bobot  $w$  dan ditambahkan dengan parameter bias  $b$  menghasilkan  $\theta$ . Kemudian setiap teta yang dihasilkan dimasukkan ke gerbang rotasi  $R$  sebagai parameter.




$$R(\phi, \theta, \omega) = \begin{bmatrix} e^{-i(\phi+\omega)/2} \cos(\theta/2) & -e^{i(\phi-\omega)/2} \sin(\theta/2) \\ e^{-i(\phi-\omega)/2} \sin(\theta/2) & e^{i(\phi+\omega)/2} \cos(\theta/2) \end{bmatrix}$$

Kata "data reuploading" pada DRC bermakna penyematan data ke sirkuit kuantum yang dilakukan secara berulang. Skema DRC sebagaimana dijelaskan pada referensi [5] memiliki kelemahan berupa semakin berkurangnya ortogonalitas antar keadaan kuantum representasi tiap kelas seiring bertambahnya jumlah kelas yang diklasifikasi, membuat *optimizer* semakin sulit menemukan parameter optimum. Skema DRC-RB yang diajukan mengatasi masalah ini dengan menggunakan qubit sebanyak  $\log_2(\text{Jumlah Kelas})$  dan label kelas dinyatakan dalam bentuk biner. Tiap qubit berperan hanya sebagai pengklasifikasi biner. Dengan begini, *optimizer* lebih mudah mencari parameter optimum. Contoh label untuk klasifikasi 4 kelas (2 qubit):  
label 0  $\rightarrow |0\rangle|0\rangle$  label 1  $\rightarrow |0\rangle|1\rangle$  label 2  $\rightarrow |1\rangle|0\rangle$  label 3  $\rightarrow |1\rangle|1\rangle$

## Principal Component Analysis (PCA)

Grafik berikut menunjukkan *explained variance* hasil PCA data MNIST 2 kelas. Terlihat hanya 6 komponen prinsip sudah mencakup 50% total variansi data.



## Konvolusi Kuantum (DRQConv)

Tugas akhir ini juga mengajukan DRQConv, teknik konvolusi dengan sirkuit kuantum. Mirip dengan konvolusi klasik, DRQConv juga menggunakan *moving window* sebagai filter. piksel yang tertutup filter diambil nilainya dan diratakan menjadi vektor  $x$ . Setiap nilai pada  $x$  akan dikalikan dengan parameter bobot  $w$  dan parameter bias  $b$  menghasilkan  $\theta$ .


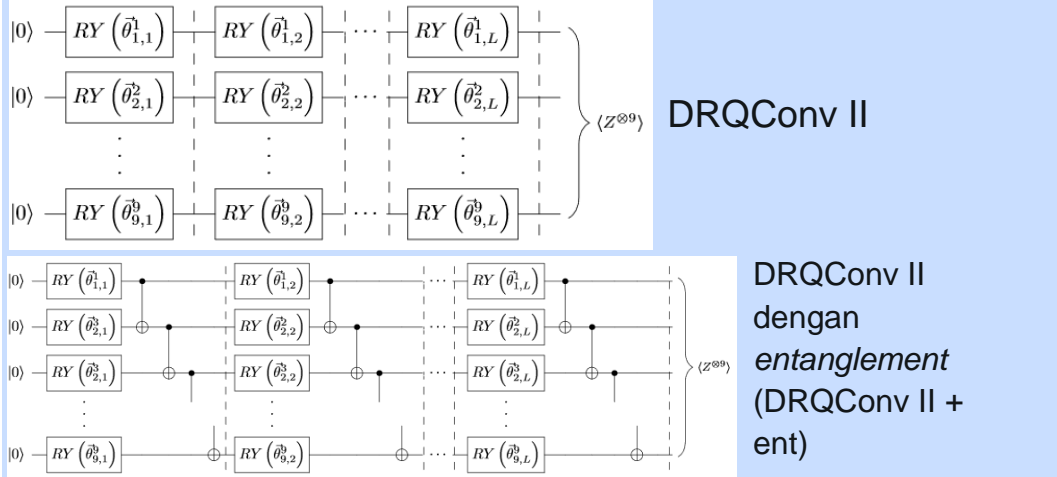


Diagram di atas menunjukkan proses konvolusi pada subcitra 3x3 yang tertutup oleh filter 3x3. Ansatz sirkuit yang digunakan pada diagram disebut DRQConv I. Pada penelitian ini dilakukan juga pengujian dengan sirkuit DRQConv II dan sirkuit DRQConv II dengan *entanglement* sebagai berikut:




Setelah melalui DRQConv sebanyak dua kali, citra kemudian dilewatkan ke filter *max pooling 2x2* dengan *stride 2*.

## Hasil Pengklasifikasi DRC dengan PCA

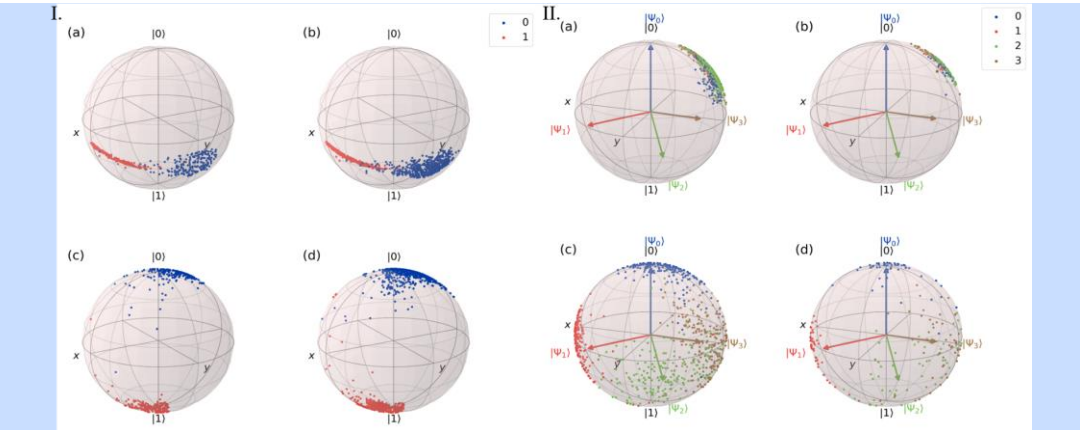
### Klasifikasi 2 & 4 Kelas (1 Qubit)

Penambahan lapisan pada DRC ternyata sangat signifikan dalam meningkatkan akurasi, jauh lebih signifikan daripada penambahan fitur. Ini menunjukan konsep data reuploading dalam DRC berperan penting dalam akurasi. Terlihat juga terjadi penurunan akurasi yang cukup signifikan dari 99,7% akurasi uji pada 2 kelas ke 91,5% pada 4 kelas.



Gambar selanjutnya menunjukkan keadaan kuantum tiap sampel pada *Bloch Sphere* (BS) sebelum (atas) dan setelah *training* (bawah). Pada klasifikasi 2 kelas (I), BS hanya terbagi ke 2 region sehingga pemisahan keadaan kuantum lebih mudah dilakukan daripada klasifikasi 4 kelas (II) yang terbagi ke 4 region.

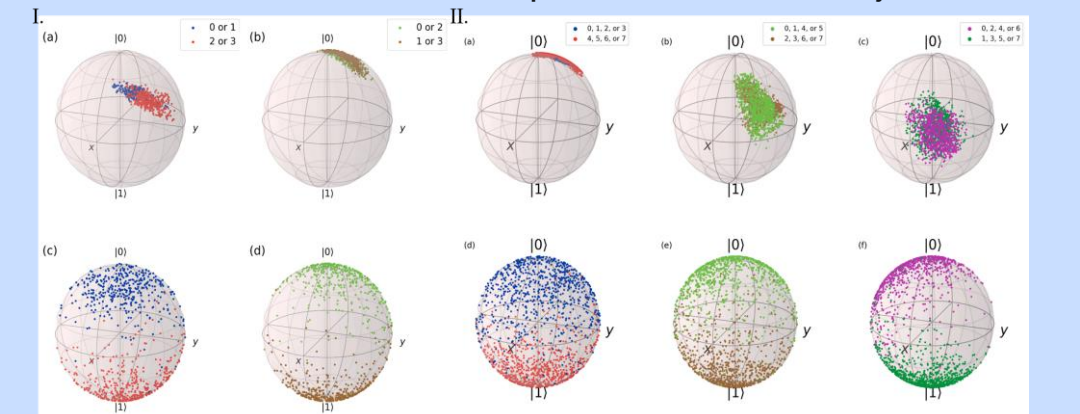
[1] Pérez-Salinas A, Cervera-Lierta A, Gil-Fuster E, Latorre JI. Data reuploading for a universal quantum classifier. *Quantum* 2020;4:226.  
[2] Farhi E, Neven H. Classification with Quantum Neural Networks on Near Term Processors 2018:1–21.



## Hasil Pengklasifikasi DRC-RB dengan PCA

### Klasifikasi 4 Kelas (2 Qubit) & 8 Kelas (3 Qubit)

Dari BS di bawah (I: 4 kelas, II: 8 kelas) terlihat separasi data berlabel berbeda tetap tidak sebaik yang kasus 2 kelas, namun hal ini tidak menjadi masalah karena semua data yang jatuh pada setengah bola yang benar akan tetap menghasilkan klasifikasi yang benar. DRC-RB meningkatkan akurasi uji sampai sebesar 5% menjadi 96,5% jika dibandingkan dengan skema DRC biasa. Pada klasifikasi 8 kelas diperoleh akurasi uji 86,25%.



## Hasil Pengklasifikasi DRC-RB dengan DRQConv

Tabel berikut merangkum akurasi terbaik yang diperoleh pada klasifikasi 2 kelas (kiri) dan 4 kelas (kanan).

Ansatz DRQConv	Akurasi Uji	Ansatz DRQConv	Akurasi Uji
DRQConv I	98,90%	DRQConv I	89,50%
DRQConv II	94,80%	DRQConv II	85,0%
DRQConv II + ent	98,70%	DRQConv II + ent	86,50%
JST Konvolusi 2 kelas	99,70%	JST Konvolusi 4 kelas	88,50%

DRQConv II menghasilkan nilai akurasi yang lebih rendah dibandingkan sirkuit lain, ini menunjukkan akurasi tidak serta merta berbanding lurus dengan jumlah qubit digunakan, arsitektur sirkuit dan bagaimana data disematkan lebih berpengaruh. Terdapat indikasi *entanglement* antar qubit dengan gerbang CNOT meningkatkan akurasi karena DRQConv II + ent menghasilkan akurasi yang lebih baik daripada DRQConv II. Pada kasus 4 kelas, pengklasifikasi dengan komputasi kuantum lebih baik sekitar 1% akurasinya dibandingkan JSTK.

## Kesimpulan

Pengklasifikasi DRC dengan PCA mencapai akurasi uji 99,7% untuk 2 kelas, jauh lebih baik dari penelitian sebelumnya, dan 91,5% untuk 4 kelas. Dengan skema DRC-RB yang diajukan, akurasi uji 4 kelas meningkat sebesar 5% menjadi 96,5%, dan pada 8 kelas menghasilkan akurasi uji 86,25%. Telah diajukan juga skema konvolusi kuantum DRQConv. Sirkuit DRQConv I dan pengklasifikasi DRC-RB mencapai akurasi uji 98,9% pada 2 kelas dan 89,5% pada 4 kelas. Kedua hasil ini cukup sepadan jika dibandingkan dengan hasil yang diperoleh JST Konvolusi.

## Referensi

[3] Skolik A, McClean JR, Mohseni M, van der Smagt P, Leib M. Layerwise learning for quantum neural networks. *Quantum Mach Intell* 2021;3:5.  
[4] Mardirosian S. Quantum-enhanced Supervised Learning with Variational Quantum Circuits. Leiden University, 2019.